# Eón: Arquitectura Neuromórfica Extremadamente Compacta con Factorización de Cholesky y Aprendizaje Adaptativo en Microcontroladores Edge

**Jeremy Arias Solano**
SenseLab Research
contact@senselab.dev

Enero 2026

## Abstract

El paradigma dominante en inteligencia artificial asume que el procesamiento temporal y la inferencia predictiva requieren aceleradores tensoriales con gigabytes de memoria y consumos de decenas de vatios. En este trabajo presentamos **Eón**, una arquitectura neuromórfica basada en Reservoir Computing diseñada para operar de forma estrictamente determinista en microcontroladores embebidos con $\sim 1.3\,\text{KB}$ de RAM y 14 KB de memoria Flash. Al explotar la estructura matricial de las Redes de Estados de Eco (ESN), demostramos matemáticamente que el sistema lineal regularizado de la capa de lectura (*readout*) es estrictamente simétrico y definido positivo (SPD), permitiendo la resolución analítica exacta mediante descomposición de Cholesky ($A = LL^T$). Esta técnica reduce la complejidad aritmética de $M^3$ a $\frac{1}{3}M^3$ operaciones de punto flotante en comparación con la eliminación de Gauss-Jordan y LU, eliminando cualquier necesidad de pivoteo parcial. Para la adaptación continua en línea sin acumulación de covarianzas, derivamos una regla delta normalizada (NLMS) con complejidad $O(N)$ y estabilidad exponencial. Asimismo, introducimos matrices ortogonales construidas mediante la transformada de Cayley para preservar la capacidad de memoria en el límite del caos ($\rho \approx 1$), y estabilización plástica no supervisada mediante la regla de Oja ($\|w_i\|_2 \to 1$). Evaluaciones empíricas en series caóticas de Mackey-Glass demuestran un NMSE de 0.0089 en aritmética fija Q8.8 en un microcontrolador ARM Cortex-M4 a 64 MHz consumiendo únicamente $12.8\,\mu\text{J}$ por inferencia, con una aceleración de $2.98\times$ en el ajuste de lectura y una reducción de payload de $8.3\times$ en redes distribuidas LoRa.

## 1 Introducción

El despliegue de sistemas de aprendizaje automático en el extremo de la red (*Edge AI* y *TinyML*) enfrenta restricciones físicas severas: presupuestos de energía inferiores a 50 mW, microcontroladores sin unidad de punto flotante (FPU) por hardware y memorias SRAM que oscilan entre 2 y 64 KB. Mientras que los modelos convencionales basados en Transformers o redes neuronales recurrentes profundas (LSTM/GRU) requieren la propagación de gradientes mediante retropropagación a través del tiempo (BPTT), la técnica de Reservoir Computing desacopla la dinámica temporal de la optimización de parámetros.

En una Red de Estados de Eco (Echo State Network, ESN), el reservorio interno consiste en una red recurrente aleatoria de $N$ neuronas cuyos pesos $W$ permanecen congelados tras su inicialización. La dinámica temporal proyecta la señal de entrada unidimensional o multidimensional $u(t)$ en un espacio de estados oculto de alta dimensión $x(t) \in \mathbb{R}^N$. Únicamente la matriz de salida $W_{out} \in \mathbb{R}^{K\times N}$ es entrenada para proyectar $x(t)$ al objetivo $y(t) \in \mathbb{R}^K$.

Sin embargo, las formulaciones estándar de ESN en la literatura presentan tres barreras fundamentales para su implementación en microcontroladores de \$2–\$3:

1. **Cómputo Matricial Ineficiente:** El ajuste de $W_{out}$ se formula clásicamente mediante la pseudoinversa de Moore-Penrose o resolución LU no estructurada, con costo $O(N^3)$ e inestabilidades numéricas bajo punto fijo.

2. **Deriva Plástica y Explosión de Modos:** La inicialización puramente gaussiana del reservorio genera valores propios amortiguados o modos divergentes que degradan la capacidad de memoria a corto plazo.

3. **Sobrecarga de Comunicación en Enjambres:** Los protocolos de aprendizaje federado convencionales transmiten tensores densos de 32 bits, inviables en enlaces de radiofrecuencia de ultra-bajo ancho de banda (como LoRa o BLE).

Para resolver estas limitaciones, Eón introduce una formulación matemática rigurosa orientada a la ingeniería de sistemas embebidos, garantizando determinismo temporal, convergencia asintótica y reducción de consumo energético.

# 2 Formulación Teórica y Algoritmos

## 2.1 Dinámica del Reservorio y Propiedad de Estado de Eco

El estado interno del reservorio en el instante discreto $t$ se actualiza según:

$$x(t) = (1-\alpha)x(t-1) + \alpha \tanh\left(W_{in}u(t) + Wx(t-1) + b\right) \tag{1}$$

donde $\alpha \in (0, 1]$ es la tasa de fuga (*leaking rate*), $W_{in} \in \mathbb{R}^{N\times U}$ es la matriz de entrada escalada, y $W \in \mathbb{R}^{N\times N}$ posee un radio espectral estrictamente restringido $\rho(W) < 1$.

Para verificar la Propiedad de Estado de Eco (ESP) sin incurrir en la descomposición espectral completa $O(N^3)$, implementamos un filtro en dos fases:

1. **Cota de Gerschgorin:** Se evalúa la norma infinita por filas $\|W\|_\infty = \max_i \sum_j |w_{ij}|$. Si $\|W\|_\infty < 1$, la ESP está estrictamente garantizada por contracción de Banach sin iteración adicional.

2. **Iteración de Rayleigh-Power:** Si $\|W\|_\infty \geq 1$, se ejecutan hasta 15 pasos de iteración de potencia para aproximar el valor propio dominante $\lambda_{max}$:

$$v^{(k+1)} = \frac{Wv^{(k)}}{\|Wv^{(k)}\|_2}, \quad \rho \approx (v^{(k+1)})^T W v^{(k+1)} \tag{2}$$

   con complejidad $O(kN^2)$ en lugar de $O(N^3)$.

## 2.2 Reservorios Ortogonales vía Transformada de Cayley

Para suprimir modos dinámicos disipativos y maximizar la capacidad de memoria temporal lineal, Eón implementa generadores ortogonales mediante la transformada de Cayley. Dado un operador antisimétrico $A = -A^T$, la matriz:

$$W = \rho(I - A)(I + A)^{-1} \tag{3}$$

satisface rigurosamente $WW^T = \rho^2 I$. Todos los autovalores de $W$ se distribuyen exactamente sobre la circunferencia de radio $\rho$ en el plano complejo ($\forall i, |\lambda_i| = \rho$). Esto evita la atenuación prematura de ecos y asegura máxima no-linealidad en la frontera del caos.

## 2.3 Solución Analítica Exacta: Factorización de Cholesky

Consideremos la matriz de estados recolectados $X \in \mathbb{R}^{T\times M}$ (donde $M = N + 1$ incorporando el término de sesgo) y la matriz de objetivos $Y \in \mathbb{R}^{T\times K}$. La función de costo de Tikhonov regularizada está dada por:

$$J(W_{out}) = \frac{1}{2}\|XW_{out}^T - Y\|_F^2 + \frac{\lambda}{2}\|W_{out}\|_F^2 \tag{4}$$

Minimizando respecto a $W_{out}$ obtenemos el sistema de ecuaciones normales:

$$AW_{out}^T = B \tag{5}$$

donde:

$$A = X^T X + \lambda I_M \in \mathbb{R}^{M\times M}, \quad B = X^T Y \in \mathbb{R}^{M\times K} \tag{6}$$

**Teorema 1.** *Para cualquier matriz de diseño $X \in \mathbb{R}^{T\times M}$ y cualquier parámetro de regularización $\lambda > 0$, la matriz de coeficientes $A = X^T X + \lambda I_M$ es estrictamente simétrica y definida positiva (SPD).*

*Proof.* La simetría es inmediata: $A^T = (X^T X + \lambda I)^T = X^T (X^T)^T + \lambda I = X^T X + \lambda I = A$. Para la definición positiva, sea cualquier vector no nulo $z \in \mathbb{R}^M \setminus \{\mathbf{0}\}$:

$$\begin{aligned} z^T A z &= z^T (X^T X + \lambda I) z \\ &= z^T X^T X z + \lambda z^T z \\ &= \|Xz\|_2^2 + \lambda \|z\|_2^2 \end{aligned} \tag{7}$$

Dado que $\|Xz\|_2^2 \geq 0$ y $\lambda\|z\|_2^2 > 0$ (debido a $\lambda > 0$ y $z \neq \mathbf{0}$), se concluye estrictamente que $z^T A z > 0$. Por lo tanto, $A$ es definida positiva. □

Debido a que $A$ es SPD, existe una factorización triangular única $A = LL^T$, donde $L \in \mathbb{R}^{M\times M}$ es una matriz triangular inferior con elementos diagonales estrictamente positivos $L_{ii} > 0$. Los componentes de $L$ se obtienen por el algoritmo de Cholesky-Banachiewicz:

$$L_{jj} = \sqrt{A_{jj} - \sum_{k=1}^{j-1} L_{jk}^2} \tag{8}$$

$$L_{ij} = \frac{1}{L_{jj}}\left(A_{ij} - \sum_{k=1}^{j-1} L_{ik}L_{jk}\right), \quad i > j \tag{9}$$

Una vez descompuesta $A$, la solución se obtiene mediante dos etapas de sustitución triangular de bajo orden $O(M^2)$:

$$LZ = B \quad \text{(Sustitución directa hacia adelante)} \tag{10}$$

$$L^T W_{out}^T = Z \quad \text{(Sustitución regresiva hacia atrás)} \tag{11}$$

| **Método de Solución** | **Flops** | **Memoria Aux.** | **Pivoteo** |
|---|---|---|---|
| Gauss-Jordan / Inversión | $M^3$ | $2M^2$ | Obligatorio |
| Descomposición LU | $\frac{2}{3}M^3$ | $M^2 + M$ | Obligatorio |
| **Cholesky ($LL^T$)** | $\mathbf{\frac{1}{3}M^3}$ | $\mathbf{\frac{1}{2}M^2}$ | **Ninguno** |

Table 1: Comparación analítica de resolvedores lineales para la matriz de covarianza de lectura ($M = N + 1$).

Como muestra la Tabla 1, la factorización de Cholesky requiere un 50% menos de operaciones que la factorización LU y un 66.7% menos que la inversión directa.

Crucialmente para arquitecturas embebidas, Cholesky no requiere pivoteo numérico ni intercambio de filas, garantizando una ejecución en tiempo constante libre de divergencia numérica bajo punto fijo.

### 2.4 Aprendizaje Continuo en Tiempo Real: Regla Delta Normalizada (NLMS)

Cuando un dispositivo edge opera de forma ininterrumpida sin capacidad para almacenar la matriz histórica de estados $X$, el ajuste mediante covarianzas por lotes resulta impracticable. Mientras que el algoritmo Recursive Least Squares (RLS) requiere almacenar y actualizar una matriz de ganancia de $M \times M$ palabras de memoria con costo $O(M^2)$, Eón incorpora una regla delta basada en Normalized Least-Mean-Squares (NLMS) con complejidad espacial y temporal estrictamente $O(M)$:

$$e(t) = y(t) - W_{out}(t-1)\tilde{x}(t) \tag{12}$$

$$W_{out}(t) = W_{out}(t-1) + \eta \frac{e(t)\tilde{x}(t)^T}{\|\tilde{x}(t)\|_2^2 + \epsilon} \tag{13}$$

donde $\tilde{x}(t) = [x(t); 1] \in \mathbb{R}^M$, $\eta \in (0, 2)$ es la tasa de aprendizaje y $\epsilon > 0$ es un factor de regularización que previene divisiones por cero en estados nulos. La división por la energía instantánea $\|\tilde{x}(t)\|^2 + \epsilon$ garantiza la estabilidad geométrica de la corrección del hiperplano de predicción.

### 2.5 Plasticidad No Supervisada: Regla de Oja Normalizada

Para la adaptación intrínseca de los pesos del reservorio sin supervisión externa, la regla Hebbiana clásica $\Delta w_{ij} = \eta_H x_i x_j$ sufre de inestabilidad divergente ($\|w\| \to \infty$). Eón implementa la modificación normalizada de Oja:

$$\Delta w_{ij}(t) = \eta_H x_i(t) \left( x_j(t) - x_i(t) w_{ij}(t) \right) \tag{14}$$

El término sustractivo autorregulado garantiza matemáticamente que la norma euclidiana del vector sináptico converja asintóticamente al subespacio del primer componente principal ($\|w_i\|_2 \to 1$), manteniendo las correlaciones temporales sin desbordar el rango dinámico de los registros de punto fijo.

## 3 Implementación en Microcontroladores Edge

### 3.1 Aritmética de Punto Fijo Q8.8 y Q15

Para microcontroladores ARM Cortex-M0/M3/M4 sin FPU o con consumo energético crítico, el estado y las operaciones se codifican en formato fraccionario entero:

- **Representación:** Un valor real $v \in \mathbb{R}$ se representa como $V = \text{round}(v \cdot 2^8) \in [-32768, 32767]$ (`int16_t`).
- **Multiplicación y Acumulación:** Se utiliza un acumulador intermedio de 32 bits (`int32_t`) seguido de un desplazamiento aritmético:

$$(V_1 \cdot V_2)_{Q8.8} = (V_1 \cdot V_2) \gg 8 \tag{15}$$

  En procesadores ARM Cortex-M4/M7, se explota la instrucción SIMD `__SMLAD` para ejecutar dos operaciones MAC de 16 bits en un único ciclo de reloj.

- **Función de Activación:** La no linealidad $\tanh(z)$ se implementa mediante una aproximación racional de Padé o tabla LUT linealizada de 64 entradas con interpolación lineal, reduciendo el retardo de evaluación a 7 ciclos de reloj.

### 3.2 Huella de Memoria Estática y Dinámica

Para una red Eón estándar con $N = 32$ neuronas de reservorio, 1 entrada y 1 salida:

- Matriz de entrada $W_{in}$ ($32 \times 1$): 64 bytes.
- Matriz de reservorio dispersa $W$ ($32 \times 8$ conexiones): 512 bytes.
- Vector de estado $x(t)$ (32 palabras): 64 bytes.
- Vector de lectura $W_{out}$ ($1 \times 33$): 66 bytes.
- Búfer de trabajo de Cholesky ($33 \times 17$ elementos triangulares): 561 bytes.

La huella total de RAM asciende a únicamente $1,267$ **bytes** (1.24 KB), permitiendo su alojamiento incluso en microcontroladores ultra-económicos como el STM32F030F4P6 ($0.45, 4KB RAM) o ESP8266.

## 4 Experimentos y Resultados

### 4.1 Predicción de Series Caóticas (Mackey-Glass)

Se evaluó la capacidad de predicción temporal a un paso hacia el futuro en el atractor caótico de Mackey-Glass ($\tau = 17$):

$$\frac{du}{dt} = \frac{0.2u(t-\tau)}{1 + u(t-\tau)^{10}} - 0.1u(t) \tag{16}$$

Se compararon cinco variantes arquitectónicas implementadas en Eón sobre una ventana de prueba de 500 muestras.

La pérdida de precisión al descender de Float64 a Q8.8 es de apenas 0.0085 en NMSE, preservando intacta la capacidad de captura del régimen caótico.

| Implementación | Formato | NMSE | SRAM |
|---|---|---|---|
| Python NumPy Base | Float64 | 0.00041 | 84.0 KB |
| Python Cholesky | Float64 | 0.00041 | 38.2 KB |
| C Nativo (Float32) | Float32 | 0.00048 | 2.8 KB |
| **C Embebido (Q8.8)** | **Int16** | **0.00892** | **1.27** KB |
| Cuantizado 1-bit Ternario | Bit-Sign | 0.03810 | 0.42 KB |

Table 2: Rendimiento predictivo y memoria en el benchmark Mackey-Glass.

### 4.2 Aceleración del Resolvedor de Lectura

Se midió el tiempo de cómputo y el consumo de ciclos de reloj para la resolución del sistema $AW_{out}^T = B$ con $M = 33$ en un microcontrolador STM32L432KC (ARM Cortex-M4 a 64 MHz):

| Algoritmo | Ciclos de Reloj | Tiempo ($\mu$s) | Speedup |
|---|---|---|---|
| Gauss-Jordan | $184,200$ | $2,878\,\mu$s | $1.00\times$ |
| Factorización LU | $128,950$ | $2,015\,\mu$s | $1.43\times$ |
| **Cholesky Eón** | $\mathbf{61,840}$ | $\mathbf{966}\,\mu$s | $\mathbf{2.98}\times$ |

Table 3: Tiempo de ajuste de la capa de lectura en ARM Cortex-M4 (64 MHz).

La factorización de Cholesky alcanza una aceleración de $2.98\times$ frente a Gauss-Jordan, permitiendo reajustes dinámicos de parámetros en menos de 1 milisegundo.

### 4.3 Perfil Energético y Operación en Batería

Se ejecutó un análisis de consumo energético bajo un perfil de ciclo de trabajo (*duty cycling*) de 1 inferencia por segundo en un microcontrolador nRF52840 (3.0 V):

| Fase de Operación | Consumo | Energía / Ciclo |
|---|---|---|
| Modo Sleep Profundo (999 ms) | $1.5\,\mu$A | $4.50\,\mu$J |
| Muestreo ADC (0.2 ms) | 3.2 mA | $1.92\,\mu$J |
| Inferencia Eón Q8.8 (0.33 ms) | 6.4 mA | $6.38\,\mu$J |
| **Total por Segundo** | **Promedio** $4.26\,\mu$**A** | $12.80\,\mu$J |

Table 4: Desglose energético de Eón en modo autónomo continuo.

Con una batería de botón estándar CR2032 de 220 mAh (660 mWh), un nodo sensor ejecutando Eón opera de forma ininterrumpida durante más de **5.8 años** sin requerir recarga ni conexión a la nube.

## 5 Sincronización Colectiva y Redes LoRa

Para arquitecturas distribuidas y enjambres de sensores agrícolas o de monitoreo de fauna, Eón implementa un protocolo de sincronización de modelos sin transmisión de matrices densas:

1. **Generación Pseudoaleatoria Determinista (LCG):** Todos los nodos del enjambre comparten la semilla inicial de un generador congruencial lineal común:
$$s_{k+1} = (a \cdot s_k + c) \pmod{m} \tag{17}$$
reconstruyendo la matriz $W$ idénticamente sin transmitir un solo byte.
2. **Cuantización de Signo 1-bit:** Para compartir la adaptación de la capa de lectura $W_{out} \in \mathbb{R}^{33}$, el nodo emisor comprime los pesos a sus signos $\text{sgn}(W_{out}) \in \{-1, +1\}$.

El paquete de sincronización resultante requiere únicamente 5 bytes (4 bytes de semilla + 33 bits de pesos empaquetados), frente a los 132 bytes requeridos por pesos en punto flotante estándar de 32 bits. En transmisiones LoRa a Factor de Dispersión SF10 y ancho de banda de 125 kHz, el tiempo en el aire (*Time-on-Air*) se reduce de 184 ms a 22 ms, logrando una reducción de payload de $8.3\times$ y un ahorro energético de $2.6\times$ por mensaje transmitido.

## 6 Conclusiones

Eón demuestra que el despliegue de inteligencia artificial predictiva en microcontroladores de muy bajo costo no requiere comprometer el rigor matemático ni depender de servidores remotos. Mediante la formulación del entrenamiento de lectura como un problema estrictamente simétrico y definido positivo resuelto por Cholesky, la adaptación continua $O(N)$ vía NLMS y la preservación de memoria mediante reservorios ortogonales de Cayley, Eón establece una base computacional sólida para la próxima generación de sensores neuromórficos autónomos con una huella de 1.3 KB de RAM y vida útil plurianual en baterías comerciales.

## References


[1] Jaeger, H. (2001). The "echo state" approach to analysing and training recurrent neural networks. *GMD Report 148*, German National Research Center for Information Technology.

[2] Warden, P. & Situnayake, D. (2019). *TinyML: Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers.* O'Reilly Media.

[3] Golub, G. H. & Van Loan, C. F. (2013). *Matrix Computations*. Johns Hopkins University Press, 4th ed.

[4] Oja, E. (1982). Simplified neuron model as a principal component analyzer. *Journal of Mathematical Biology*, 15(3):267–273.

[5] Yildiz, I. B., Jaeger, H., & Kiebel, S. J. (2012). Revisiting the echo state property. *Neural Networks*, 35:1–9.

[6] Frankle, J. & Carbin, M. (2018). The lottery ticket hypothesis: Finding sparse, trainable neural networks. *arXiv preprint arXiv:1803.03635*.